



PROJET MACHINE LEARNING

Hamza SILABDI, Paul BARTHELEMY, Andréa MASSE, Florian GAUDIN

07 JANVIER 2025

ISUP

Table des matières

I.	Présentation des données et de la problématique assurantielle donnée.....	2
II.	Analyse préliminaire des données :.....	2
a)	Nettoyage des données	2
b)	Analyse de la corrélation des variables	3
III.	Applications des différents modèles	6
a)	Arbre de régression	6
b)	Forêt aléatoires.....	7
c)	RidgeCv.....	7
d)	LassoCv	8
IV.	Comparaison des résultats	9

I. Présentation des données et de la problématique assurantielle donnée

L'évolution des systèmes de santé et des conditions socio-économiques a un impact significatif sur l'espérance de vie des populations. Dans ce projet, nous avons cherché à identifier les principaux facteurs influençant l'espérance de vie dans différents pays en nous basant sur une base de donnée contenant des informations socio-économiques et sanitaires afin d'effectuer une prédiction de l'espérance de vie. Ces données incluent différents indicateurs tels que :

- **Life expectancy** : L'espérance de vie en fonction de l'âge (variable cible)

Et quelques variables explicatives comme par exemple :

- **GDP_per_capita** : Le PIB par habitant
- **Adult Mortality** : Taux de mortalité des adultes des deux sexes (probabilité de mourir entre 15 et 60 ans pour 1000 habitants)
- **Measles** : nombre de cas de rougeole signalés pour 1000 habitants
- **Infant deaths** : Nombre de décès infantiles pour 1000 habitants
- **Economy_status_Developed** : Statut développé ou en développement

Ces variables permettent d'étudier l'impact de différents facteurs sur l'espérance de vie et d'identifier les déterminants majeurs de la longévité.

Ensuite, en exploitant des techniques de Machine Learning, nous avons mis en place différents modèles afin de prédire l'espérance de vie d'un pays donné en fonction de multiples variables explicatives.

L'objectif principal de cette étude est donc double :

1. Comprendre les relations entre les variables socio-économiques et sanitaires et leur influence sur l'espérance de vie.
2. Déterminer le modèle prédictif offrant la meilleure performance pour estimer l'espérance de vie en comparant plusieurs approches.

Ainsi, nous allons répondre dans ce projet à la problématique suivante : Peut-on prédire efficacement l'espérance de vie d'un pays à partir de facteurs socioéconomiques et de santé en utilisant des modèles de Machine Learning et comment évaluer la pertinence des prédictions obtenues ?

II. Analyse préliminaire des données :

a) Nettoyage des données

Le jeu de données contient des données de 193 pays entre 2000 et 2015. Or, nous avons décidé de nous concentrer uniquement sur les pays d'Europe. Ainsi, une première étape consistait au nettoyage des données ou nous avons filtré sur uniquement les données des pays d'Europe.

Ensuite, on a constaté qu'il y avait des données manquantes (par exemple 172 et 35 pour les variables Hepatitis B et Alcohol). Plusieurs stratégies de remplissage des données manquantes ont été appliquées :


Premièrement via un remplissage avec la moyenne des trois années les plus proches. Si un pays avait une valeur manquante pour une année donnée, la donnée a été complétée avec la moyenne des trois années les plus proches. Deuxièmement via un remplissage avec la moyenne de la région. Si un pays avait des valeurs manquantes pour toutes les années, les données ont été complétées avec la moyenne de la Région (par exemple Asie, Afrique, Union Européenne : ici on a juste eu besoin de l'appliquer pour l'Union Européenne) .

Après vérification, le jeu de données est bien complet.

b) Analyse de la corrélation des variables

Pour finir, on a décidé d'analyser la corrélation entre les variables afin de sélectionner les variables les plus pertinentes pour estimer l'espérance de vie et d'éliminer celles qui sont non significatives.

Premièrement, commençons par observer le graphe des corrélations :



Voici ensuite une approche en plusieurs étapes pour analyser la pertinence des variables :

1) Analyse de la corrélation linéaire (Pearson) :


Cette mesure permet d'évaluer la relation linéaire entre deux variables en attribuant un coefficient de corrélation compris entre -1 et 1. Un coefficient proche de 1 indique une forte corrélation positive, tandis qu'un coefficient proche de -1 indique une forte corrélation négative.

La corrélation de Pearson est indiquée par la valeur du coefficient de corrélation r calculée à l'aide de la formule suivante :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Where:
 r = Pearson Correlation Coefficient
 x_i = x variable sample y_i = y variable sample
 $\bar{x}$ = mean of values in x variable $\bar{y}$ = mean of values in y variable

Voici les résultats obtenus :



Ainsi, on constate que certaines variables comme Hepatitis_B ou Alcohol_consumption sont non significatives pour la prédiction à l'inverse de GDP_per_capita ou Economy_status_Developed qui sont très corrélés à l'espérance de vie.

2) Test de régression linéaire multiple

Afin de comparer avec les résultats observés avec l'analyse précédente, nous réalisons un test de régression linéaire multiple.

Pour rappel, étant donné un échantillon $(Y_i, X_{i1}, \dots, X_{ip})_{i \in \{1, n\}}$, on cherche à expliquer, avec le plus de précision possible, les valeurs prises par Y_i , notre variable cible (l'espérance de vie), à partir d'une série de variables explicatives $X_{i1}, \dots, X_{ip}$. Le modèle théorique, formulé en termes de variables aléatoires, prend la forme

$$Y_i = a_0 + a_1 X_{i1} + a_2 X_{i2} + \dots + a_p X_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

où ε_i est l'erreur du modèle qui exprime, ou résume, l'information manquante dans l'explication linéaire des valeurs de Y_i à partir des $X_{i1}, \dots, X_{ip}$ (problème de spécifications, variables non prises en compte, etc.). Les coefficients $a_0, a_1, \dots, a_p$ sont les paramètres à estimer.

Avant de s'intéresser à la significativité des variables, on constate que notre modèle est globalement significatif avec un excellent ajustement des données expliqué par un $R^2 = 0,978$ (indiquant que le modèle explique 97,8% de la variance de l'Espérance de vie) et F-statistic = 1603 avec une p-value faible confirmant que le modèle est globalement significatif.

Dep. Variable:	Life_expectancy	R-squared:	0.978
Model:	OLS	Adj. R-squared:	0.978
Method:	Least Squares	F-statistic:	1603.


Ensuite, on peut confirmer la non significativité de certaines variables comme Polio , Thinnest_five_nine_years ou Schooling qui affichent des p_values nettement supérieur à 0,05 (donc nous pouvons rejeter H0)

	coef	std err	t	P> t	[0.025	0.975]
const	-87.8238	18.621	-9.773	0.000	-117.613	-78.254
Year	0.1289	0.006	15.758	0.000	0.116	0.136
Infant_deaths	-0.6362	0.147	-4.321	0.000	-0.925	-0.347
Under_five_deaths	0.4438	0.138	3.455	0.001	0.124	0.704
Adult_mortality	-0.0448	0.002	-52.888	0.000	-0.048	-0.042
Alcohol_consumption	-0.1388	0.035	-8.852	0.000	-0.145	-0.091
Democracy_9	-0.0055	0.002	-2.258	0.024	-0.010	-0.001
Resiles	-0.0088	0.003	-3.244	0.001	-0.016	-0.008
WII	-0.0429	0.058	-0.389	0.698	-0.571	0.480
Polio	-0.0268	0.013	-1.277	0.200	-0.043	0.000
Diphtheria	0.0328	0.012	2.792	0.006	0.010	0.055
Incidents_HIV	0.3785	0.423	2.313	0.021	0.148	1.009
GDP_per_capita	1.367e-05	1.07e-06	6.877	0.000	8.53e-06	1.74e-05
Population_mln	0.0307	0.001	8.038	0.000	0.008	0.015
Tuberculosis_million_years	-0.7731	0.232	-2.638	0.009	-1.240	-0.158
Tuberculosis_1990_2000_years	0.0644	0.268	0.525	0.746	-0.426	0.505
Schooling	0.0040	0.028	0.154	0.878	-0.047	0.055
Economy_status_Developed	-48.3434	4.387	-9.675	0.000	-58.165	-38.555
Economy_status_Developing	-87.1841	9.024	-9.668	0.000	-99.201	-75.158

Par la suite, il va être utile d'explorer un modèle régularisé comme Ridge ou Lasso pour gérer la multicolinéarité et améliorer la robustesse des prédictions. (multicolinéarité expliqué par Condition Number = $6,60 \times 10^{19}$)

Ainsi, à la fin de cette analyse, les variables présentant une très faible corrélation avec l'espérance de vie ont été supprimées.

Nous avons visualisé les relations entre quelques variables clés identifiées précédemment et la variable cible :




Les différents graphes montrent clairement une forte corrélation entre la variable cible et les variables explicatives ici présentées. Par exemple pour le PIB, on observe une corrélation positive : à mesure que le PIB par habitant (GDP_per_capita) augmente, l'espérance de vie tend également à augmenter. Cependant, il semble y avoir un effet de saturation au-delà d'un certain seuil de PIB (vers 60 000 USD), où l'espérance de vie cesse d'augmenter de manière significative.

III. Applications des différents modèles

Après cette analyse préliminaire des données, nous appliquons plusieurs modèles de Machine Learning afin de prédire l'espérance de vie. Pour cela, nous avons choisi de tester 4 méthodes différentes : un arbre de régression, une forêt aléatoire, une régression Ridge et une régression Lasso.

a) Arbre de régression


On commence par réaliser un arbre de régression qui segmente les données en sous-ensembles selon les valeurs des variables explicatives en minimisant l'erreur. On obtient dans un premier temps un classement d'importance des variables :




La métrique ici calculée est le RMSE, c'est-à-dire la classique racine de la moyenne quadratique des erreurs (différence entre la valeur prédite et la valeur réelle) au carré. Le RMSE est une métrique intéressante car il est homogène à la variable cible et représente donc directement l'erreur moyenne de prédiction, qui est ici très faible (environ 0,55) par rapport à l'ordre de grandeur de nos données.

Ce classement des importances (l'importance est comprise entre 0 et 1, et la somme des importances de chacune des variables du modèle est égale à 1) nous indique les variables qui contribuent le moins au modèle et qui pourraient donc être exclues des prochaines modélisations en vue d'une simplification. Par exemple, le PIB représente environ 76% de la réduction totale de l'erreur alors que la rougeole en représente seulement 0,1% !

On choisit donc de supprimer les variables du statut économique et de la rougeole, puis on relance une modélisation avec un arbre et on observe visuellement les résultats :






Visuellement, les prédictions ont l'air bonnes (on procédera à la fin à une analyse des erreurs quand on comparera les différentes méthodes utilisées).

b) Forêt aléatoires

La forêt aléatoire se comporte comme un ensemble d'arbres de décision. Chaque arbre est construit indépendamment des autres. Les forêts aléatoires consistent à faire tourner en parallèle un grand nombre (plusieurs centaines) d'arbres de décisions construits aléatoirement, avant de les moyenner. En termes statistiques, si les arbres sont décorrélés, cela permet de réduire la variance.

Ainsi, implémentons alors une forêt de 500 arbres afin de moyenner les prédictions individuelles de chacun des arbres et ainsi améliorer la prédiction globale de l'espérance de vie :



Visuellement, on voit qu'on a moins d'écart avec les valeurs qui étaient précédemment les moins bien prédites. De plus, le RMSE a été réduit de 22% (environ 0,341) .

c) RidgeCv

Le modèle RidgeCV (Ridge avec Validation Croisée) associe la régression Ridge, une méthode de régression linéaire régularisée, à la validation croisée pour sélectionner automatiquement le meilleur hyperparamètre α (celui qui minimise l'erreur de prédiction sur l'ensemble de validation). La régression Ridge applique une pénalité L2 à la fonction de coût afin de limiter l'influence des coefficients excessivement élevés et de réduire le risque de sur-apprentissage. La validation croisée, quant à elle, permet d'évaluer la performance du modèle en le testant sur différentes subdivisions de l'ensemble de données.


Fonction de coût de Ridge :

$$J(w) = \text{MSE} + \alpha \sum_{i=1}^n w_i^2$$

La fonction de coût inclut l'erreur quadratique moyenne (MSE) et un terme de régularisation L2, où α contrôle le degré de régularisation appliqué aux coefficients.

Ce procédé permet d'obtenir un modèle plus robuste et mieux adapté à la généralisation sur de nouvelles données.

Voici donc les prédictions obtenus à l'aide de cette méthode :



On constate que le modèle RidgeCV offre également des prédictions précises et bien corrélées aux valeurs réelles, avec une dispersion faible et une bonne généralisation (La distribution des points autour de la droite montre que les erreurs de prédiction sont relativement faibles et homogènes).

d) LassoCv

Après avoir testé le modèle RidgeCV, utilisons un autre modèle de régression pénalisée pour pouvoir ensuite comparer leur efficacité.

Pour rappel, LassoCV, à l'instar de RidgeCV, est une variante de la régression linéaire régularisée, mais utilise cette fois une pénalité L1 dans sa fonction de coût (réduction de certains coefficients à zéro). Cette régularisation a pour objectif de limiter le surajustement du modèle en contraignant les coefficients des variables explicatives.


Fonction de coût de Lasso :

$$J(w) = \text{MSE} + \alpha \sum_{i=1}^n |w_i|$$

La fonction de coût comprend l'erreur quadratique moyenne (MSE) et un terme de régularisation L1. Le paramètre α contrôle l'intensité de la régularisation : une valeur élevée de α entraîne une pénalisation plus forte des coefficients.

LassoCV permet d'obtenir un modèle robuste, en réduisant le risque de surajustement tout en sélectionnant automatiquement les variables les plus pertinentes.

Voici les résultats observés à l'aide de ce modèle :




On constate une dispersion plus importante des prédictions, avec une tendance à sous-estimer les valeurs élevées et à surestimer les plus basses. Cela suggère que la régularisation appliquée par Lasso supprime certaines variables importantes, entraînant une perte de précision. De plus, le RMSE est plus élevé que les modèles précédents (1,92). Ainsi, LassoCV semble être moins efficace que les modèles testés précédemment.

IV. Comparaison des résultats

Une fois les modèles entraînés, il est crucial d'évaluer leurs performances afin d'identifier leur capacité de généralisation et leurs limites. Dans cette section, nous nous concentrons donc sur l'analyse des résidus, qui représentent les différences entre les valeurs réelles et les valeurs prédites par nos modèles.

Voici donc les résultats obtenus pour chaque méthodes utilisées :




Les erreurs semblent centrées autour de 0, ce qui est très bien car cela signifie que, globalement, le modèle ne présente pas de biais systématique : il ne surestime ni ne sous-estime systématiquement les valeurs.

Globalement, les erreurs restent entre -1 et 1 donc cela veut dire qu'on fait en général une erreur de ± 1 sur l'estimation de l'espérance de vie avec un arbre de régression.

Cependant, quelques valeurs dépassent ce seuil, mais on a, au maximum, une erreur de -2 ans, ce qui reste relativement acceptable.


Pour finir, l'absence d'une structure claire suggère que le modèle capture bien la tendance globale, mais il souffre de forte variance, ce qui est un inconvénient classique des arbres de décision.




De même, les erreurs semblent centrées autour de 0. Pour la forêt, l'estimation est encore meilleure car les résidus sont moins dispersés.

En effet, on le voit encore ici puisque la grande majorité des erreurs sont comprises entre -0,75 et 0,75, et on a, au maximum, une erreur de -1.

Ce modèle semble mieux généraliser par rapport à l'arbre de décision, car il réduit les erreurs extrêmes




Les résidus de ce modèle se rapprochent de ceux de l'arbre, c'est-à-dire que la plupart sont compris entre -1 et 1 mais ne dépassent cette fois-ci pas le seuil de $\pm 1,5$.



On constate bien une forte dispersion des résidus (de -4 à +4) indiquant des erreurs importantes sur certaines prédictions. De plus, on observe une tendance signifiant que LassoCv ne capture pas totalement certaines relations non linéaires dans les données.

Ainsi, bien que LassoCV puisse être utile pour simplifier le modèle en sélectionnant les variables les plus importantes, il semble moins performant que RidgeCV et la Forêt Aléatoire en termes de précision.

Pour terminer, on va comparer, à l'aide de différentes métriques (R^2 , MAE, RMSE), la qualité des modèles :



La comparaison des modèles montre que la Forêt Aléatoire est le plus performant, avec les erreurs les plus faibles (RMSE, MAE) et un R^2 élevé, indiquant une forte capacité prédictive. RidgeCV offre un bon compromis, limitant le surajustement tout en maintenant une bonne précision. L'arbre de régression suit avec des performances acceptables, bien qu'il présente une légère variance. LassoCV, en revanche, est le moins efficace, avec des erreurs plus élevées et un R^2 plus faible, probablement en raison d'une régularisation excessive éliminant des variables importantes. Globalement, la Forêt Aléatoire se distingue comme le meilleur modèle pour prédire l'espérance de vie.

Conclusion :

L'objectif de ce projet était d'analyser les facteurs influençant l'espérance de vie dans les pays européens et de développer des modèles prédictifs performants en utilisant différentes approches de Machine Learning. À travers différentes étapes incluant une analyse exploratoire des données, une sélection des variables pertinentes et l'application de plusieurs modèles de régression, nous avons pu identifier les principales tendances et comparer les performances des algorithmes testés.

L'analyse statistique et la régression linéaire multiple ont mis en évidence des variables influentes, notamment le PIB par habitant, la mortalité infantile et adulte, ainsi que certains indicateurs de santé publique. Ces facteurs ont été intégrés dans 4 modèles principaux : l'arbre de régression, les régressions Ridge et Lasso avec validation croisée (RidgeCV) et la forêt aléatoire.

Les résultats des modèles couplés à l'analyse des résidus et des différentes métriques montrent que la forêt aléatoire s'est révélée être le modèle le plus adapté pour la prédiction de l'espérance de vie dans notre cas.

Pour compléter cette étude, il pourrait être intéressant d'explorer des modèles avancés tels que les réseaux de neurones afin d'améliorer encore les performances prédictives.